Segmentos de precio de departamentos en CABA

¿Podemos identificar el segmento alto a partir de superficie, ambientes y barrio?

Proyecto integrador · Programación Avanzada en Ciencia de Datos

Publicaciones de 2020 · Clasificación binaria · scikit-learn + SQLite

Datos y preparación

Control	Resultado
Publicaciones originales	156.258
Duplicados exactos eliminados	205
Superficies / ambientes fuera de límites	18 / 29 → faltantes
Barrios faltantes	10
Publicaciones tras la limpieza	156.053

Muestra de avisos, con repetición de inmuebles. No incluye antigüedad.
Límites declarados: 10–1000 m² y 1–20 ambientes; la imputación se aprende después.

Fuente: BA Data · data.buenosaires.gob.ar/dataset/departamentos-venta · Muestra 2020

Objetivo y separación de los datos

Segmento alto = precio mayor a USD 235.000

Umbral: percentil 75 calculado únicamente con entrenamiento.
Es una categoría de precio relativa; no significa lujo.

Separación por dirección normalizada

124.576 publicaciones para entrenar y 31.477 para evaluar.
Ningún grupo de dirección está compartido entre ambas particiones.

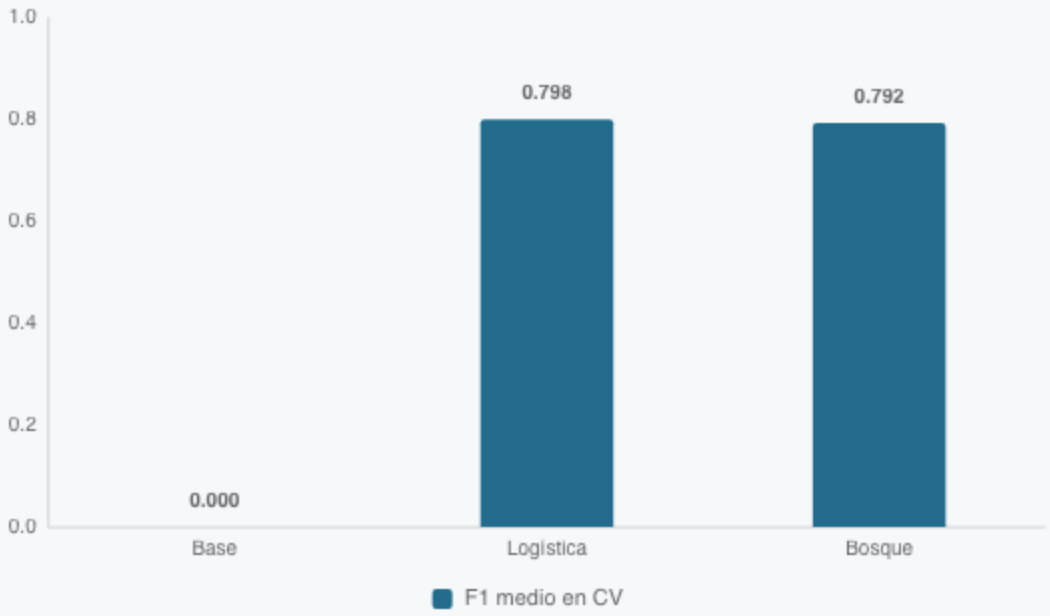
Predictores: superficie, ambientes y barrio

Se excluyen precio en dólares, pesos y precio por m^2.
Usarlos permitiría reconstruir la respuesta y produciría fuga de información.

Pipeline y selección por validación cruzada

Numéricas: mediana + escalado
Barrio: faltante explícito + OneHotEncoder
El preprocesamiento se ajusta dentro de cada fold.

GridSearchCV · 3 folds agrupados
Logística: C y ponderación de clases
Bosque: profundidad y mínimo por hoja
Selección por F1 de clase alta, antes de prueba.



Elegida por CV: Regresión Logística.
C = 10; clases balanceadas.

Resultados en publicaciones reservadas

Modelo	Accuracy	Precision	Recall	F1
Base	0.751	0.000	0.000	0.000
Logística	0.895	0.742	0.888	0.809
Bosque	0.906	0.835	0.774	0.804

Matriz de la logística · filas reales, columnas predichas

Real / predicción	Estándar	Alto
Estándar	21.219	2.415
Alto	880	6.963

La logística detecta el 88,8 % de los altos.

Accuracy base: 75,1 %, pero no detecta altos.

Base de datos y ejecución reproducible

SQLite: entrada, transformaciones y resultados

datos_limpios + datos_preprocesados
predicciones + metricas + configuracion

Python para la lógica; notebook para explicar y ejecutar

Funciones y módulos reutilizables. Pipeline guardado con joblib.
El mismo flujo se ejecuta desde Jupyter o desde ejecutar.py.

Evidencia de cada corrida

CSV de métricas y predicciones, JSON de parámetros, gráficos y log.
Semilla fija, versiones registradas y SHA-256 del dataset.

Alcance de los resultados

El modelo identifica un segmento histórico de precio

La logística obtuvo F1 = 0,809 y recall = 0,888 en prueba.
Su uso queda acotado a la muestra y a la definición de clase adoptada.

Limitaciones

Datos de 2020, concentrados en el segundo trimestre; pocos predictores.
Direcciones imperfectas, publicaciones repetidas y superficies dudosas.

Qué necesitaría una aplicación actual

Datos recientes, identificación confiable de inmuebles
y evaluación temporal independiente. Las asociaciones no son causales.